

산업공학 종합설계 최종 발표 보고서

PHM을 통한 베어링의 고장 및 남은 수명 예측

팀 명

JONBO Inc

201520190 정현석

201520178 오제윤

201520191 남기수

201520241 배찬우

201520238 이윤성

목차

- | | | | | |
|--------------|-----------|-----------|---------------------------|--------------|
| 01. 주제 선정 배경 | 02. 달성 목표 | 03. 연구 방법 | 04. LSTM 알고리즘을 이용한 FPT 계산 | |
| 05. 데이터분석 | 06. RUL계산 | 07. 계산결과 | 08. 한계점 | 09. APPENDIX |

주제 선정 배경

1)정비 개념의 변화

기존의 정비 방식

사후정비(BM)

- 문제가 발생하고 난 이후 정비
- 정비주기 X

예방정비(PM)


- 정기적으로 정비를 시행하여 문제를 예방
- 정비주기 O
- 예측 또는 경험을 통한 정비

예지정비(PHM)

- 시스템 이상 상황을 감지 및 분석
- **예지진단**을 통한 고장 시점 사전예측
- 정비주기 O
- **설비 데이터 분석**을 통한 상태 점검 및 정비

2) 기존 정비 방식의 문제점

- 기존의 정비 방식은 실제 결함 수준, 고장발생 가능성은 고려하지 않고 무조건적인 정비를 실시
- 결함 부품 뿐만 아니라 문제 없는 부품 까지 같이 교체하는 경우가 빈번
- 이에 따른 불필요한 비용이 발생



예지정비(PHM)가
정기적 예방정비의
대안으로 떠오르고 있음


PHM 이란?

PHM(Prognostics and Health Management) : 예지정비

- 기계, 설비, 항공, 발전소 등의 시스템의 상태 정보를 수집, 분석하여 이상상황을 감지 및 예지하는 활동
- 고장시점을 사전에 예측 가능
- 시스템 유지비용 절감, 안전성 측면에서 필수적

달성 목표

중간 발표까지의 결과



임계 값 0.275

- LSTM을 이용해 데이터의 이상치 판단 분석
- 모델학습을 이용한 가중치파일 확보와 임계 값 습득
- 본래 목적인 PHM을 활용한 베어링의 남은 수명 예측에는 많이 부족

최종 목표

- Machine Learning과 데이터 분석을 기반으로 베어링의 남은 유효 수명을 예측
- 검증 => 실제 RUL과 측정된 RUL 값을 비교하여 정확도 여부 판단 (RUL : remaining useful life)

연구 방법

활용 데이터확장


- NASA Bearing Data Set -> NASA FEMTO Bearing Data Set

출처) <https://ti.arc.nasa.gov/tech/dash/groups/pcoe/prognostic-data-repository/>

- 더욱 정밀한 분석을 위해 베어링 진동 정보 뿐만 아니라 온도 정보까지 포함된 data로 활용 데이터 변경

활용 데이터확장

- PRONOSTIA: 베어링 테스트 및 검증 전용 오류 감지, 진단 및 예후 접근 시스템
- 실험 플랫폼은 단 몇 시간만에 베어링의 성능 저하를 수행할 수 있다.



분석 순서

- 1) LSTM : 센서 값이 정상 범주를 벗어나는 순간을 탐지

=> RMS(Root mean square)를 사용하여 데이터 정규화를 진행

=> LSTM 알고리즘을 사용하여 예측 값의 RMS를 구함

=> 실제 값의 RMS와 예측 값의 RMS를 차이인, Loss_mae를 사용하여
FPT(First Predicting Time)를 구함



- 2) RMS와 FPT를 지수 모델 알고리즘(EM model)에 대입하여 정확한 고장 시점을 예측

LSTM 알고리즘을 이용한 FPT 계산

LSTM 알고리즘 이란?

RNN의 한 종류로 긴 의존 기간을 필요로 하는 학습을 수행할 능력 보유

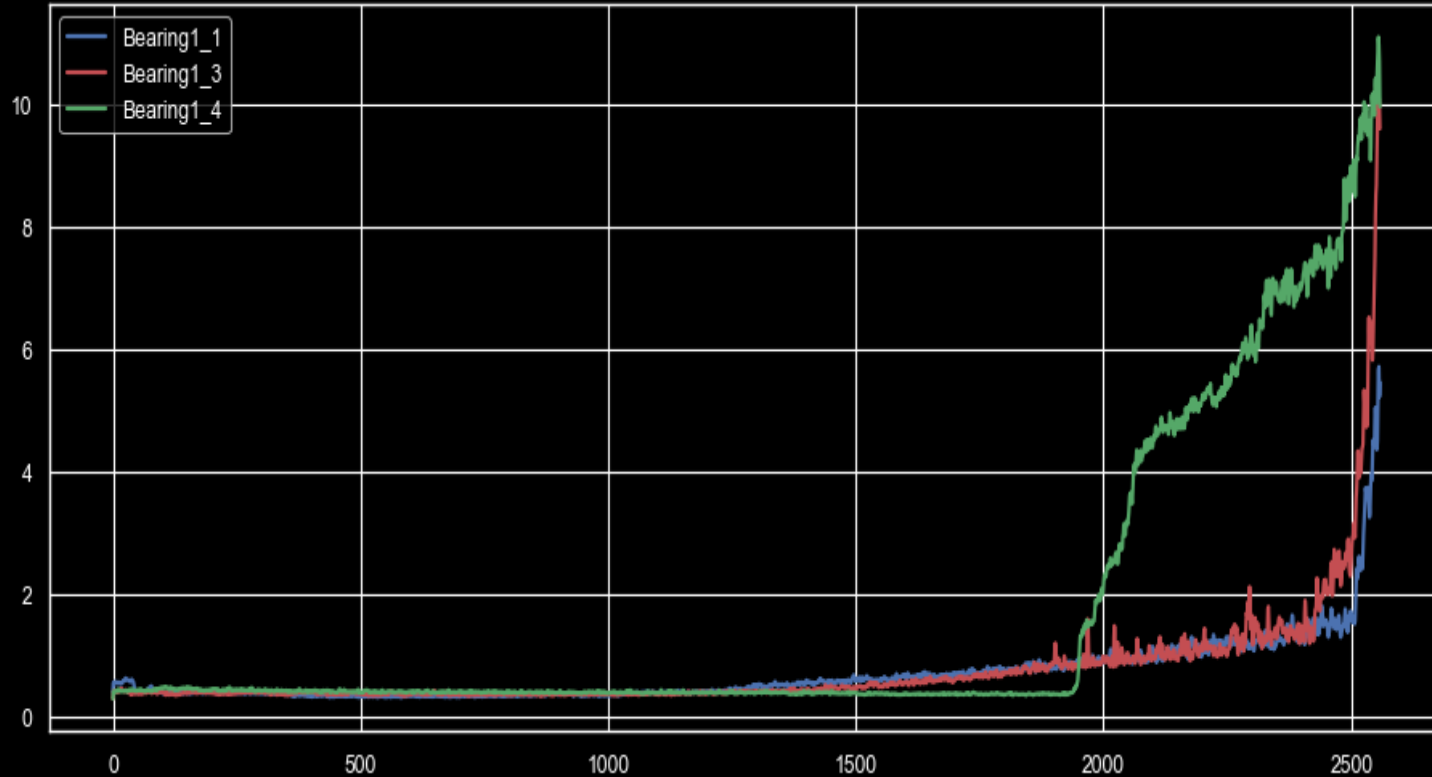
RNN과 같은 체인구조를 갖고 있지만, 각 반복 모듈은 다른 구조를 보유



1) 데이터 전처리

- LSTM 알고리즘을 이용한 FPT(Failure predicting time) 계산
- 전체 데이터를 약 2500개의 구간으로 나눠 각각 RMS를 계산
- 전체 데이터 Set을 Training Set과 Test Set으로 분할
- 데이터 정규화 및 FFT 변환

분석에 사용될 데이터 그래프

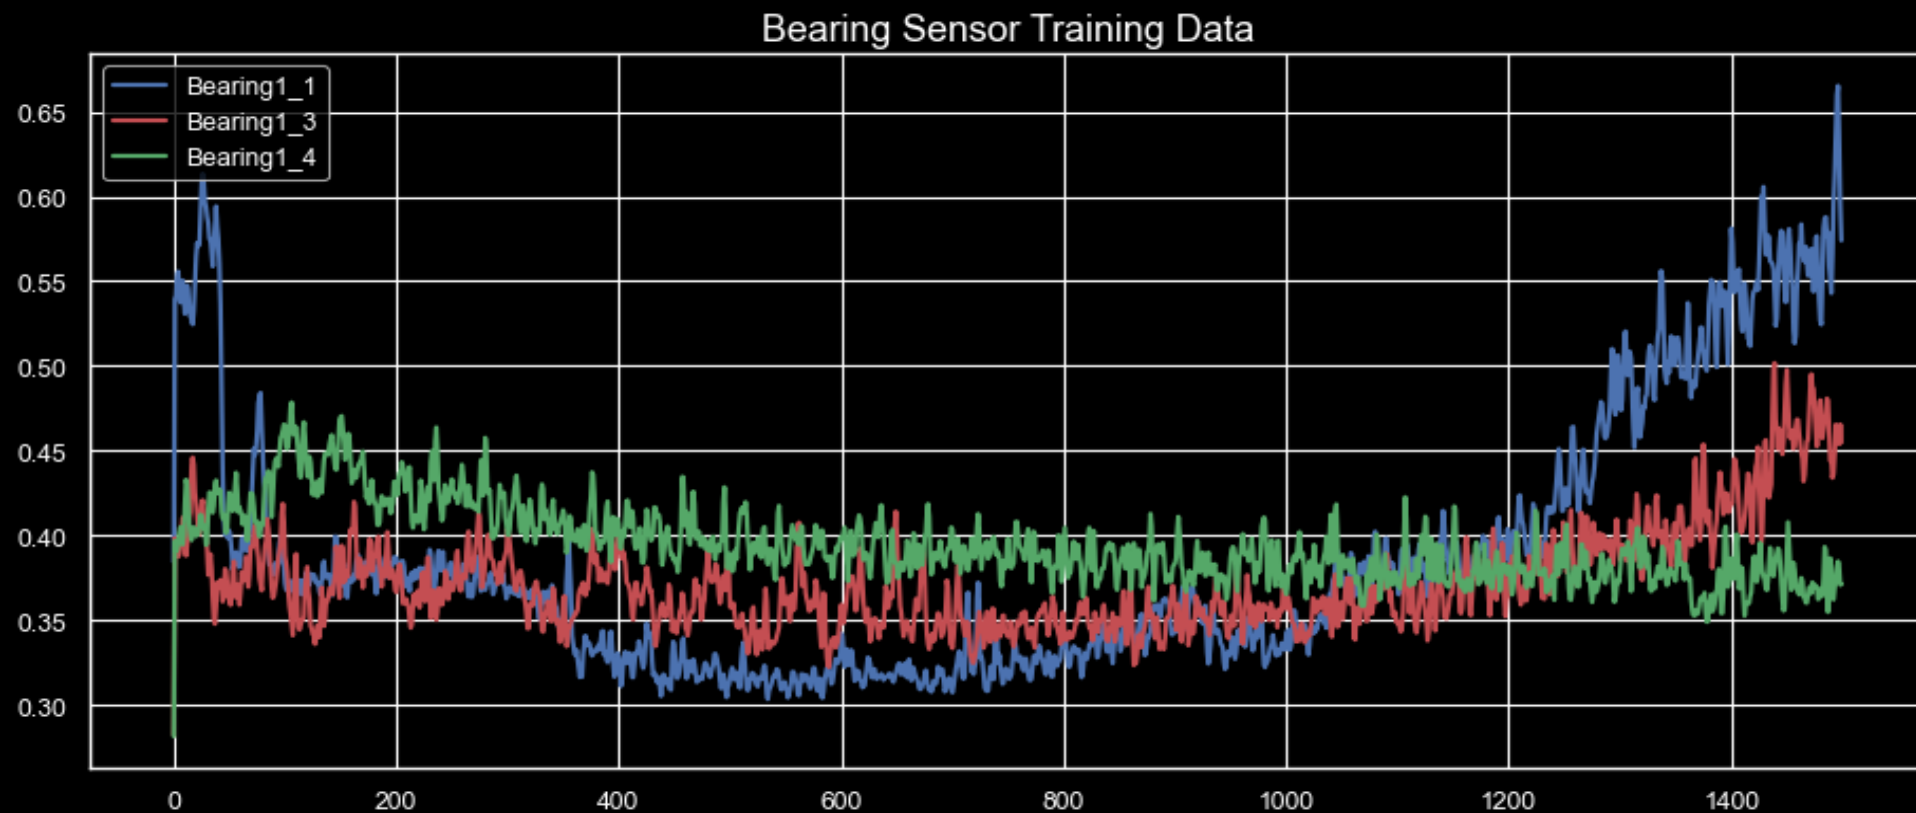


X축: 시간 / Y축: 진동수

- 정상구간에서는 일정한 모습을 보이나 고장 시기에 다다를수록 **진동수가 급격히 상승함**

Training Set 그래프

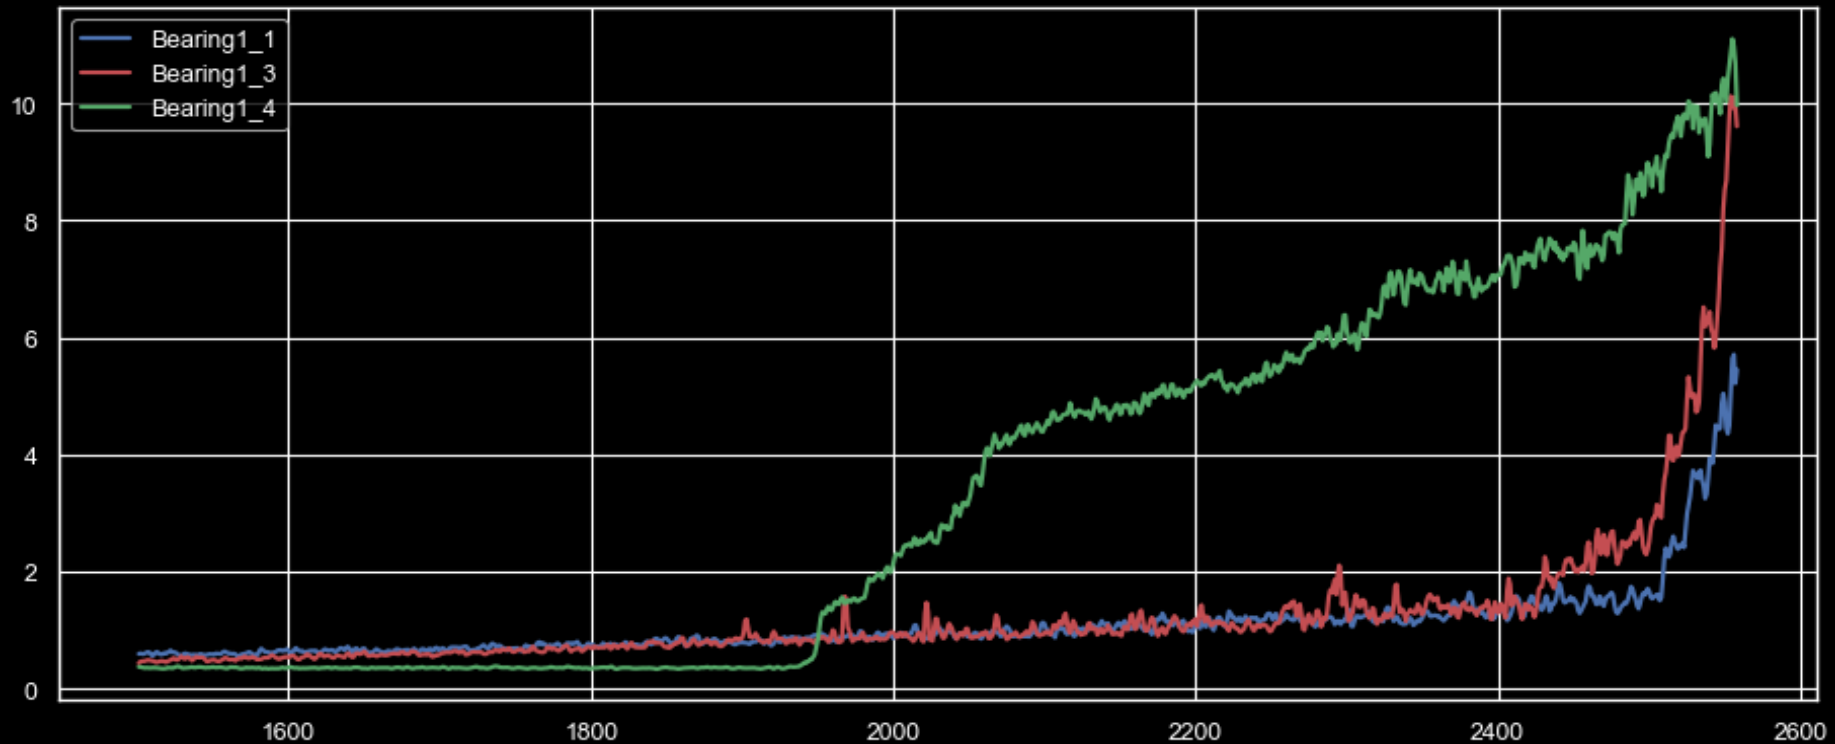
정상 작동 조건에서의 데이터



X축: 시간 / Y축: 진동수


Test Set 그래프

베어링 고장으로 이어지는 데이터



X축: 시간 / Y축: 진동수

2) 학습 모델링 - AutoEncoder

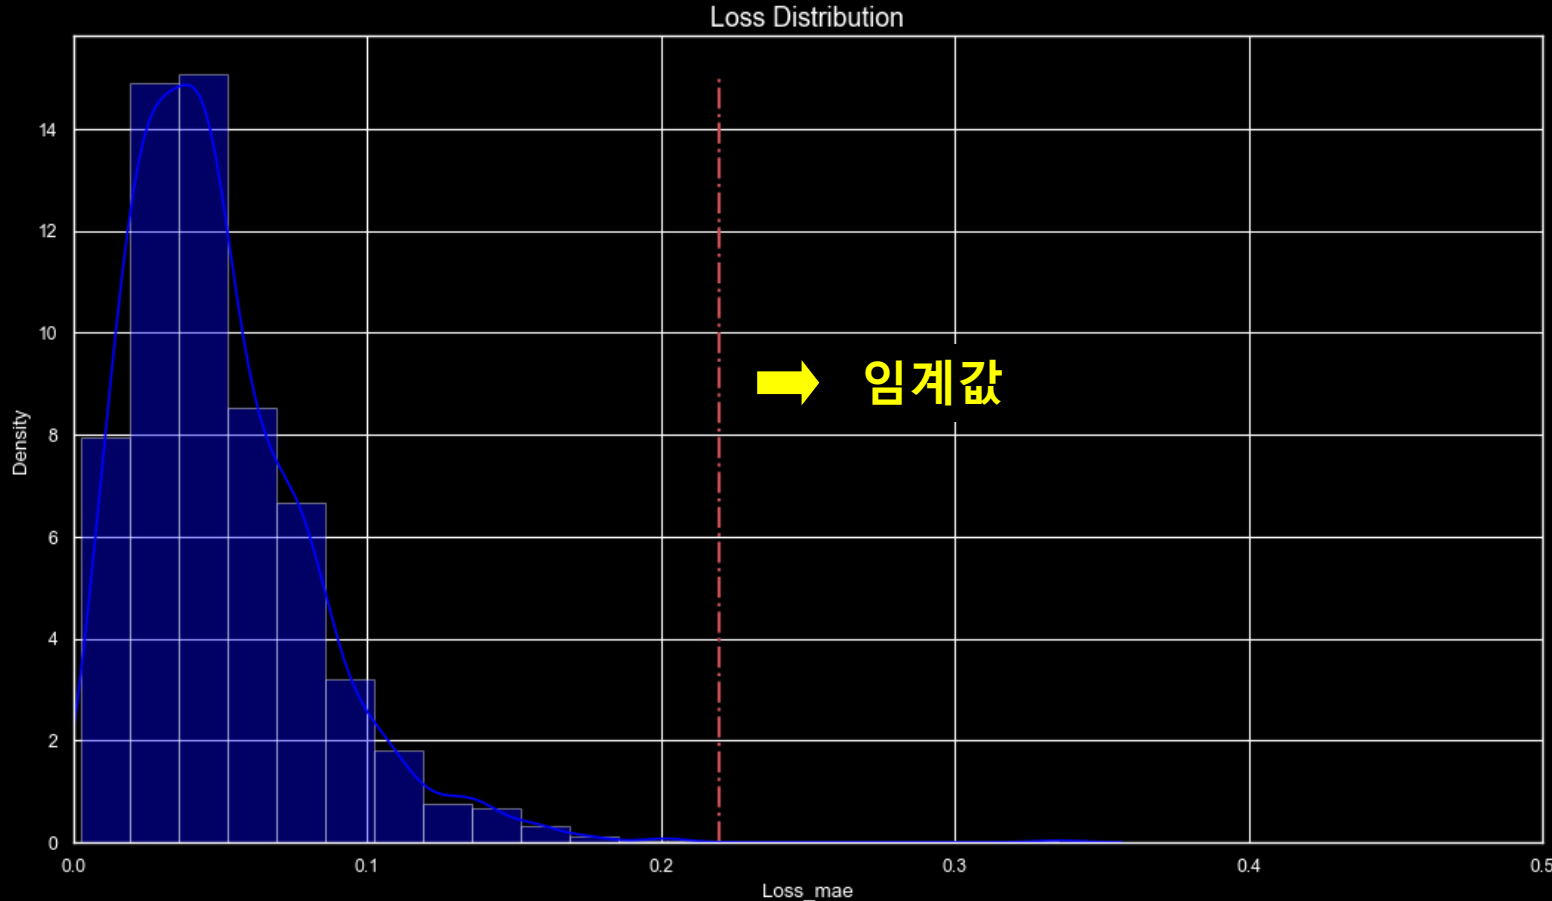


5 Layers

Epoch = 200

Batch Size = 10


3) LSTM 알고리즘 - 학습 결과



X축: Loss_mae(노이즈) / Y축: 분포

- Train 세트에서 계산된 노이즈의 분포를 표로 나타내어 이상을 식별하는 데 적합한 임계 값 결정 가능
- 실제 데이터와(Train set) 예측 값의 차이, 즉 Loss_mae(노이즈)가 0.22를 능가하지 않기때문에 임계 값을 노이즈 수준보다 높은 0.22로 설정


3) LSTM 알고리즘 - 학습 결과



X축: 시간 / Y축: Loss_mae(노이즈)

- FPT: 센서 판독 값이 정상 작동 값에서 벗어나기 시작하는 시기
- FPT는 전체의 약 66.4%가 경과한 시점으로 설정

3) LSTM 알고리즘 - 학습 결과



FPT가 데이터의 급격한 변화가 시작되는 부분보다 약간 앞에 위치한 것을 확인

데이터 분석

데이터 분석 모델 - EM 모델

- 지수분포 : 베이지안 접근 방식을 사용하여 업데이트 된 정보이며, 그 후 많은 변형 및 응용 프로그램 RUL 예측에서 지수 모델을 사용한다.

- 1. degradation models

$$x_k = \varphi + \theta' \exp \left(\beta' t_k + \sigma B(t_k) - \frac{\sigma^2}{2} t_k \right)$$

- 2. parameter estimation

논문의 FPT 및 같은 최적화 지수 모델 사용

$$\hat{\sigma}_k^{2(i+1)} = \frac{1}{k} \left(\frac{s_1^2 - 2s_1(\mu_{\theta,k} + \mu_{\beta,k}t_1) + \sigma_{\theta,k}^2 + \sigma_{\beta,k}^2}{t_1} + 2(\rho_k \sigma_{\theta,k} \sigma_{\beta,k} + \mu_{\theta,k} \mu_{\beta,k}) + t_1 (\mu_{\beta,k}^2 + \sigma_{\beta,k}^2) \right. \\ \left. + \sum_{j=2}^k \frac{(s_j - s_{j-1})^2 - (s_j - s_{j-1}) \Delta t \mu_{\beta,k} + (\Delta t)^2 (\mu_{\beta,k}^2 + \sigma_{\beta,k}^2)}{\Delta t} \right) \\ \hat{\mu}_{0,k}^{(i+1)} = \mu_{\theta,k}, \hat{\sigma}_{0,k}^{2(i+1)} = \sigma_{\theta,k}^2 \\ \hat{\mu}_{1,k}^{(i+1)} = \mu_{\beta,k}, \hat{\sigma}_{1,k}^{2(i+1)} = \sigma_{\beta,k}^2$$

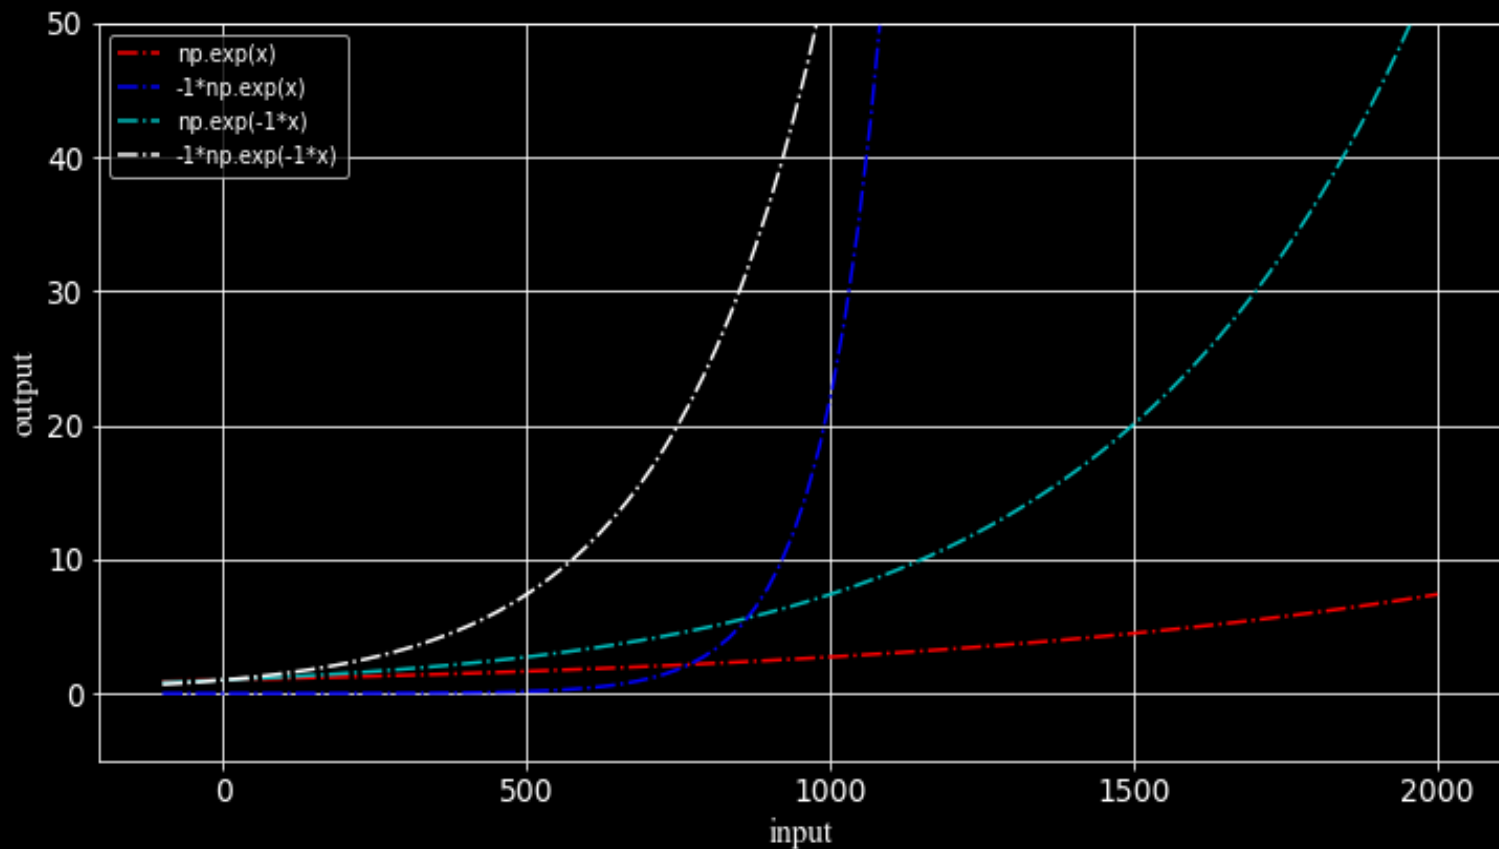
데이터 분석 모델 - EM 모델

- 3. RUL prediction

$$L_k = \inf \{l_k : s(l_k + t_k) \geq \gamma | S_{1:k}\}$$

$$f_{L_k|S_{1:k}}(l_k|S_{1:k}) = \frac{\gamma - s_k}{\sqrt{2\pi l_k^3 (\sigma_{\beta,k}^2 l_k + \hat{\sigma}_k^2)}} \times \exp \left[-\frac{(\gamma - s_k - \mu_{\beta,k} l_k)^2}{2l_k (\sigma_{\beta,k}^2 l_k + \hat{\sigma}_k^2)} \right], \quad l_k \geq 0.$$

데이터 분석 모델 - EM 모델

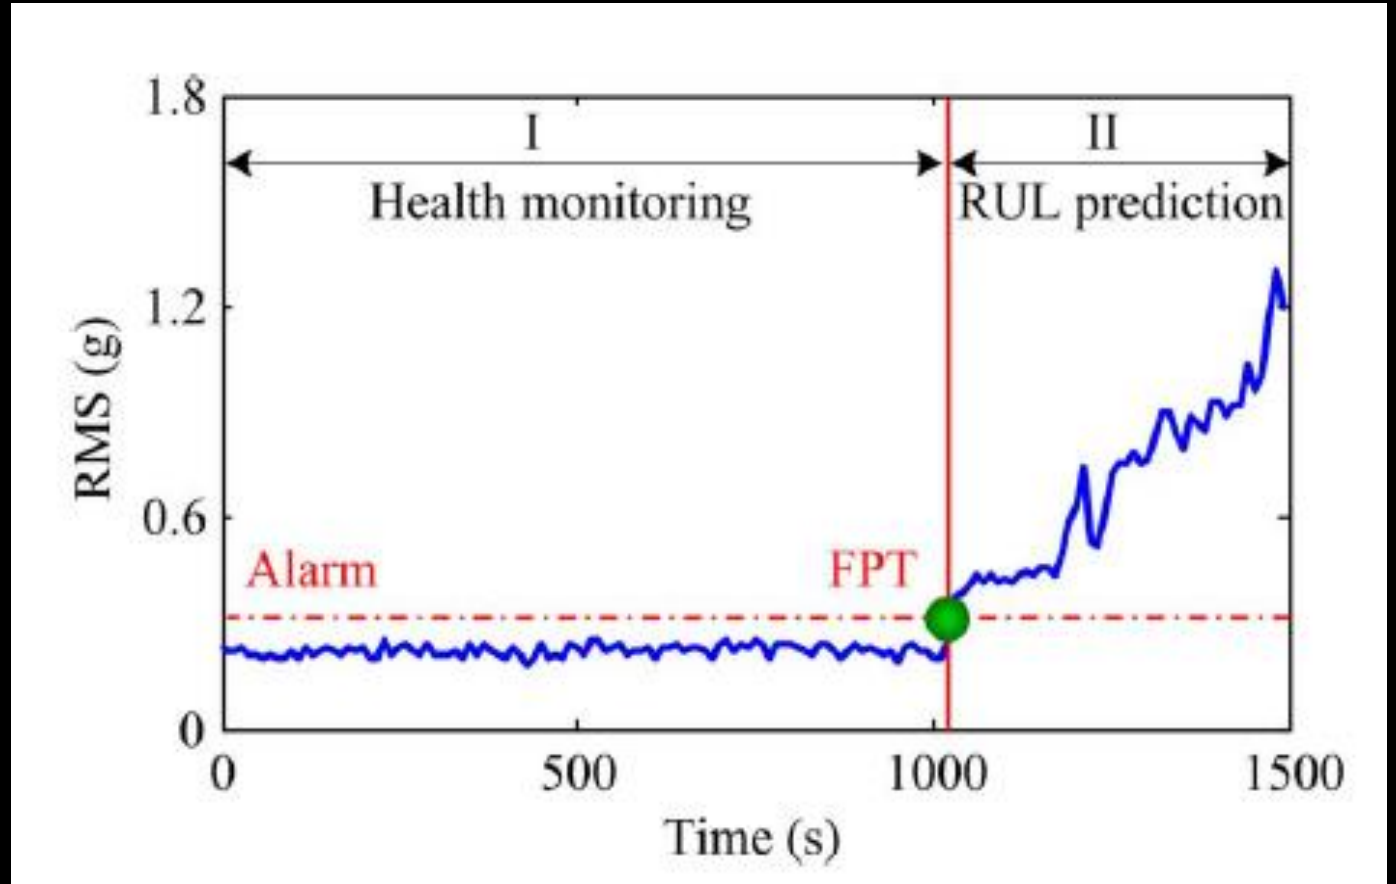


- 실제 진동 데이터의 분포가 지수적 모형을 보여주기 때문에 머신러닝의 **활성화 함수**를 **EM모델**로 지정
- 그 외 부분은 **텐서플로우** 모듈 사용

RUL 계산



Bearing degradation process

- RUL 예측은 FPT 이후부터 측정
- FPT이후로 RMS값이 급격히 변화

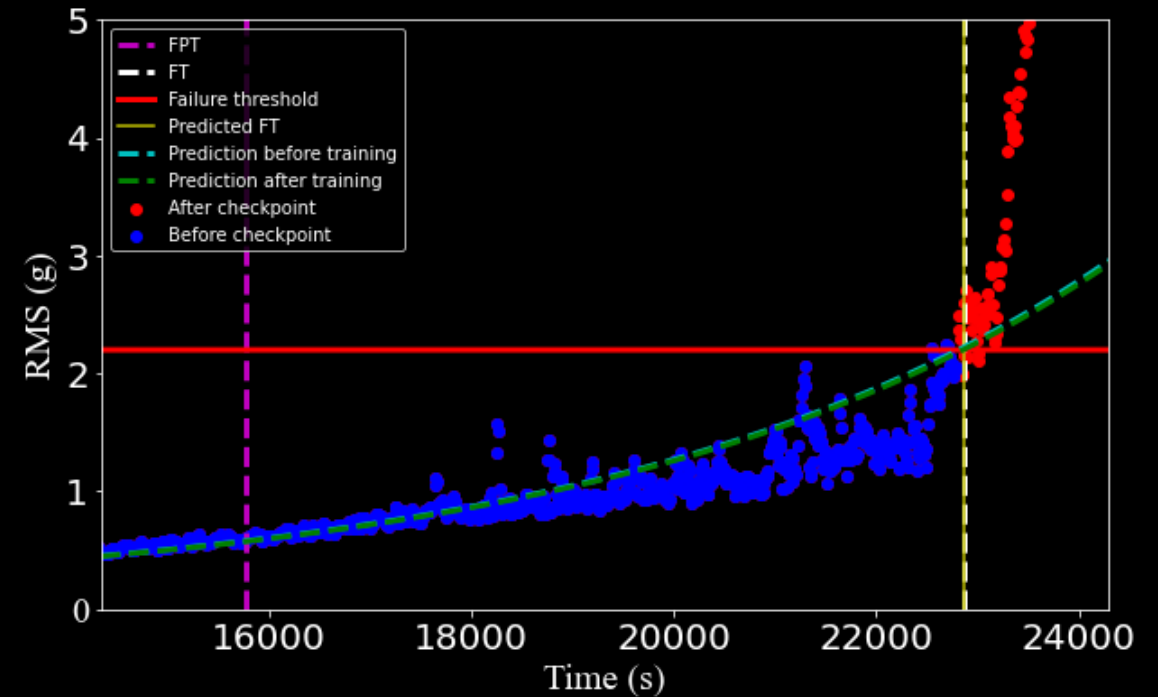
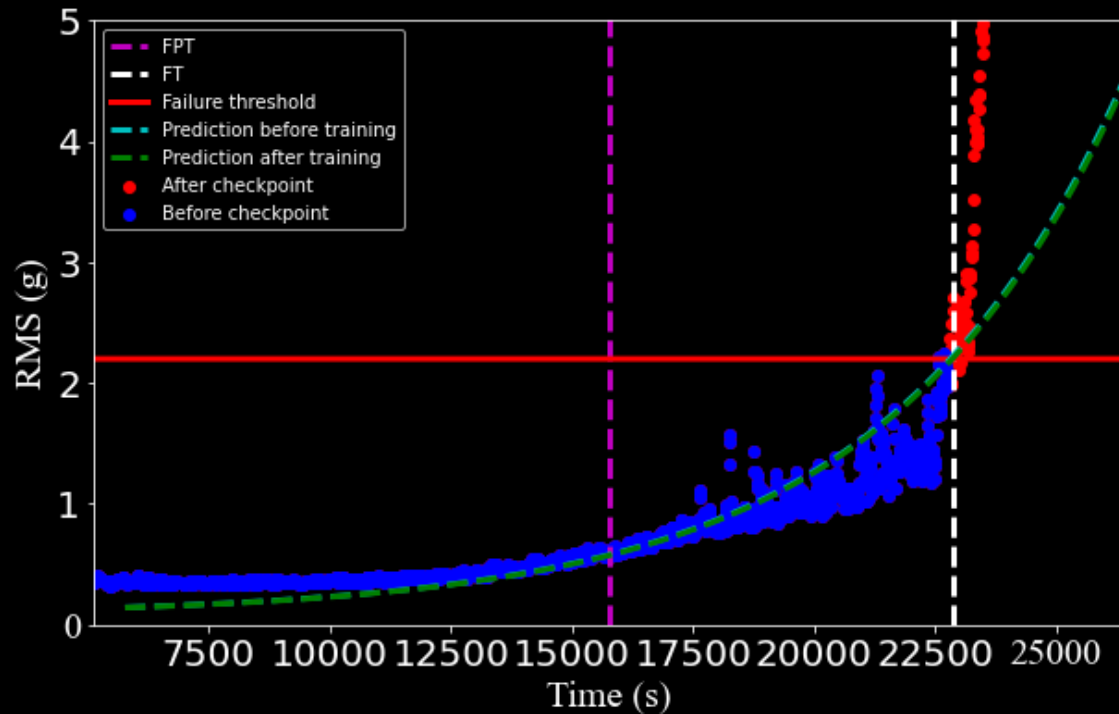


계산 결과


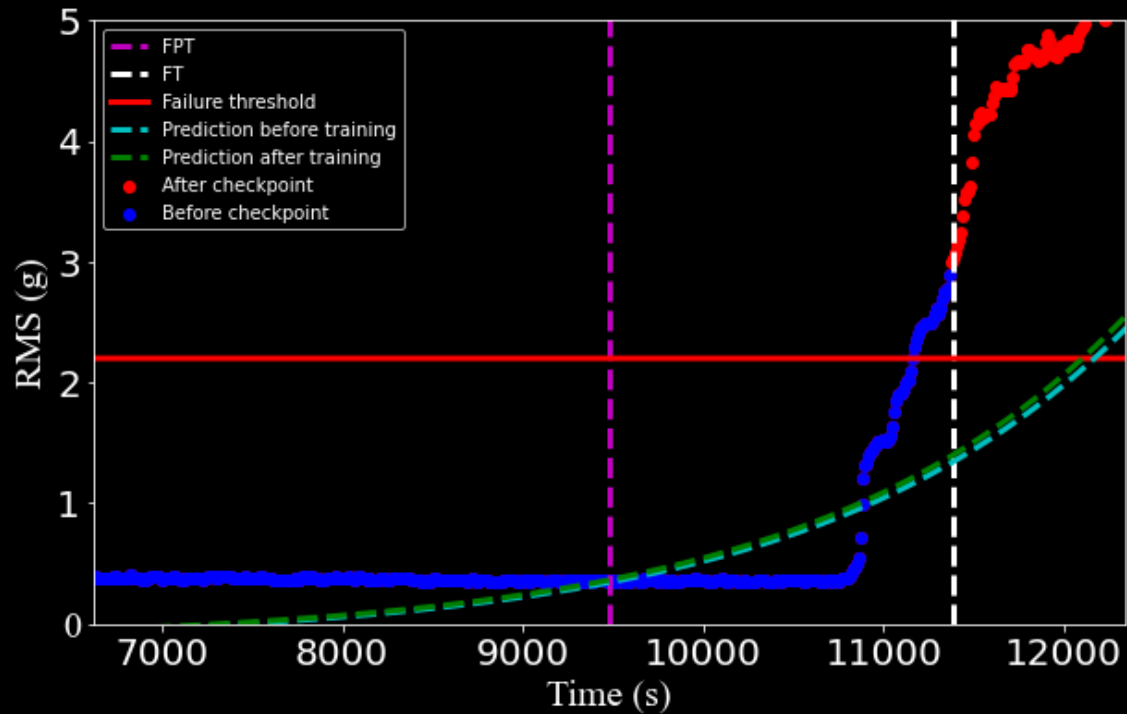
그래프 - Bearing1_1 model



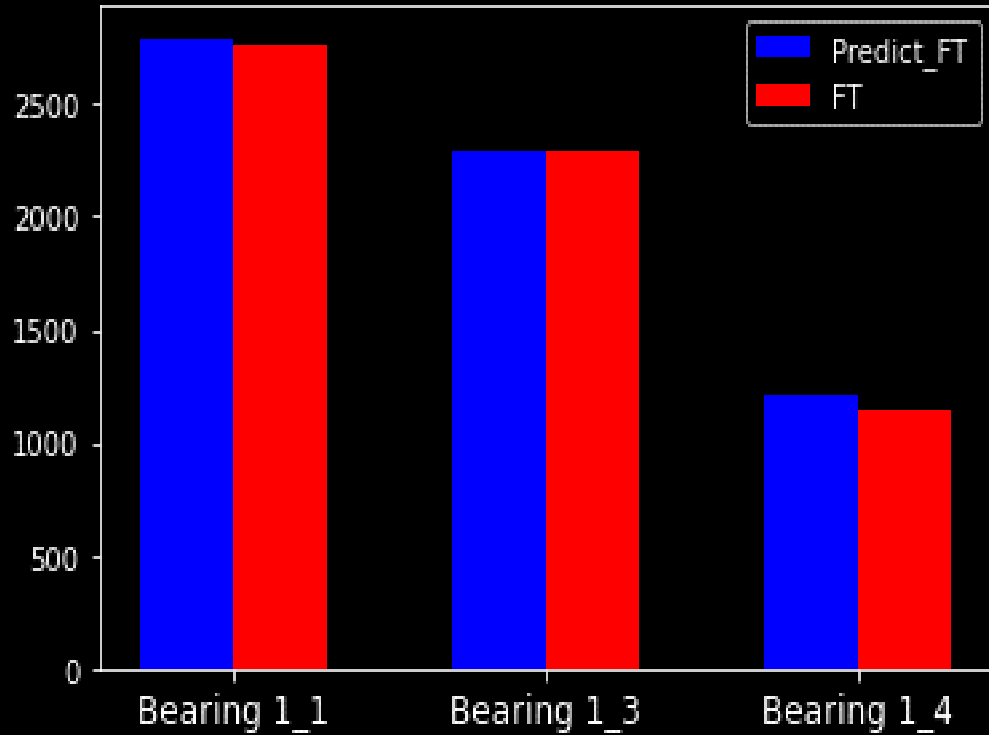
그래프 - Bearing1_3 model



그래프 - Bearing1_4 model



실제 값과 비교



(고장시점)	Bearing 1_1	Bearing 1_3	Bearing 1_4
예측	2763	2287	1139
실제	2756	2279	1261
편차	29	1	72
예측 정확도	98.95%	99.95%	93.68%

➡ 평균 예측 정확도 =
97.53%

결론

1. LSTM을 활용하여 앞으로 이상현상이 일어나기 시작하는 시점인 **FPT를 탐지**
2. EM 모델을 활용하여 **언제 고장이 일어나는지**를 예측 가능
3. LSTM알고리즘과 EM모델을 활용하여 **97.53%**의 평균예측 정확도 도출

한계점

한계점

- 1. 검증과정 미흡

RUL 계산 Training을 통해 RUL을 계산하는 과정은 구현했지만,
이를 검증하는 과정 미흡

- 2. UI구현

분석 결과를 다양하게 보여주는 시각화 시스템을 UI로 구현하고
싶었으나 시간상 어려움으로 인해 구현 실패

APPENDIX

참고 문헌 탐색

- Review on Remaining Useful Life Prediction Methods of Bearing (2020)
- A Review on Prognostics Methods for Engineering Systems (2020)
- <http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07566578>
- <https://www.researchgate.net/publication/280560510>
- <https://towardsdatascience.com/lstm-autoencoder-for-anomaly-detection-e1f4f2ee7ccf>
- <https://github.com/famer3riots/PHM-RUL-Prediction-by-EM.git>

첨부파일



Handling.py

Handling.py

- 원본 데이터 전처리 파일
(.mat 파일로 저장)



rul_final.py

Rul_final.py

- **lstm_final.py**에서 계산한 FPT값과
EM 모델을 이용한 RUL계산 파일



lstm_final.py

Lstm_final.py

- LSTM알고리즘을 이용한
FPT 계산 파일



mat1.zip

Mat1.zip

- **Handling.py**의 전처리 결과 파일